

Théorie des langages (grammaires formelles)

origines linguistiques

Chomsky 1955 MIT
(limpides) → ampliation

Syntactic structures
1ere formalisation de la grammaire

grammaires formelles
de réécriture.

cadre (réécriture / étages
machine de Turing
système de Post)

(\sum) T terminaux
en nombre fini *
Langages $\Sigma \subseteq T$

en langage des mots
200 000
300

suivant mot

ENTINUSCLES T^* suites finies de terminaux
la suite vides est possible

$(T^+ \text{ suites finies non vides })$
de terminaux

Σ ensemble pas forcément fini
de suites de terminaux (mots)

Un langage peut être décrit par un ensemble fini de règles.

Non Terminaux : NT

(ensemble fini)

200 NT

dans 1 NT particulier S
start / sentence

en MAJUSCULES

phrase
syn) agrame nominal groupe nominal
syntagme verbal groupe verbal
syntagme prépos. groupe prépositionnel

sentence
Nom phrase
verb phrase
pronominal phrase

Règle de réécriture

$$W \times W' \rightarrow W''$$

des T des NT
au moins un NT

$W, W', W'' \in (T \cup NT)^*$

$$a \times b a b z b \in (T \cup NT)^*$$

$xxz \in NT^* \subset (T \cup NT)^*$

$abaa \in T^* \subset (T \cup NT)^*$

si toutes les règles sont de la forme:

$$W \ X \ W' \rightarrow W \ M \ W' \quad W, W', M \in (T \cup NT)^*$$

X se réécrit en M
dans le contexte $W - W'$

alors on dit que la grammaire
est contextuelle.

si toutes les règles sont de la forme

$$W \times W' \longrightarrow W''$$

- $W, W', W'' \in \text{FNT}^*$

avec $|W \times W'| < |W''|$

alors la grammaire est dite

length increasing (croissante)


Kuroda (1967?)

~~Les~~ langages produits par
~~les~~ grammaires contextuelles
sont les mêmes que les
langages produits par
des grammaires length increasing

L'appartenance d'une phrase
à un langage produit (recurrence)
par une grammaire contextuelle
(ou croissante) est décidable.

) $a \ a \ b \ | = 5$

$a \ ab \ aa \in \mathcal{L}(G)$



Si toutes les règles sont
de la forme

$$X \xrightarrow{ } W'' \\ X \in NT \qquad \qquad \qquad W'' \in (T \cup NT)^*$$

alors la grammaire est dite ~~la~~

hors-contexte non contextuelles

(algébriques)

si toutes les règles sont de la forme


$$\begin{cases} X \rightarrow aY \\ au \\ X \rightarrow a \end{cases}$$

avec $X, Y \in NT$ $a \in T$

alors la grammaire est dite

ré gulière (droite)

le langage est dit rationnel



le langage

$L(bkT)$

est l'ensemble des suites

de terminaux

modélisées à partir du

terminal "spécial" S

Un langage est dit de type 0, 1, 2, 3
lorsque il existe une grammaire
régulière, hors contexte, contextuelle, génératrice

langage régulier, rationnel 0


hors contexte, algébrique 1

contextuels 2

1. c. énumérable 3

grammaires récursives

hors contexte, non contextuelle
contextuelle, croissante
générale récursive



Exos Grammaires formelles
(Deug MIAS (L2) Nantes 2001)

Donnez le type de grammaire ?

si hors contexte, langage en générale ?

$$T = \{a, b\} \quad NT = \{S, A, B\}$$

$$S \rightarrow AB$$

$$B \rightarrow SA$$

$$bB \rightarrow a$$

$$Ab \rightarrow SBb$$

$$\bullet \underline{Aa} \rightarrow SBb$$

type 3 / générale

G2) $T = \{\nearrow, \searrow\}$ $NT = \{S, A, U, V\}$

 $S \rightarrow UV$ | UV (2 règles)

 $A \rightarrow VSU$ | VU

 $U \rightarrow$ 

 $V \rightarrow$ 

G2: has contexte (for 1 NT
à garder →)

$S \rightarrow UAV \mid UV$


$A \rightarrow VSU \mid VU$

$U \rightarrow _$

$V \rightarrow _$

$S \rightarrow \underline{UAV} \rightarrow UVSUV \rightarrow \dots$

$\dots \rightarrow UVUVUVUV \dots$




Quel est le langage engendré

$$\mathcal{L}(G_2) = \left\{ (\text{S L})^n \mid n \in \mathbb{N}^* \right\}$$

Comment montrer que $\mathcal{L}(G_2) = \left\{ (\text{S L})^n \mid n \in \mathbb{N}^* \right\}$

① $\mathcal{L}(G_2) \subset \left\{ (\text{S L})^n \mid n \in \mathbb{N}^* \right\}$

② $\left\{ (\text{S L})^n \mid n \in \mathbb{N} \right\} \subset \mathcal{L}(G_2)$



2ème étape $(UV)^{2P} \hookrightarrow (UV)^{2P}$

2_{p+1} étape $(UV)^{3P} U A V (UV)^{3P}$

Si

2p ionic charz $(UV)^{2p}$ S $(UV)^{2p}$ ~~weak~~
2p+1 ionic charz $(UV)^{2p+1}$ UAV $(UV)^{2p}$ ~~g~~

$\downarrow A \rightarrow VSU$

elas

2p+2 charz $(UV)^{2p+2}$ S $(UV)^{2p+2}$
2p+3 charz $(UV)^{2p+3}$ UAV $(UV)^{2p+2}$

per recurrence

G_{ab}^m

$S \rightarrow ab \quad | \quad aSb$

$a^n b^n \quad n > 0$

$S \rightarrow aSb \rightarrow aaSbb$

$\rightarrow aabb$

$f_m > 0$

$a^n b^n \in L(G_{ab^n})$

pour $n = 1$ c'est vrai $S \rightarrow ab$

Supposons que $S \rightarrow a^u b^n$

montrons que $S \rightarrow a^{u+1} b^{n+1}$

$S \xrightarrow{\text{hyp ind}} a^u S b \xrightarrow{S \rightarrow a^u b^n} a^{u+1} b^{n+1}$

Si $S \rightarrow W$ alors W est
de la forme
 $a^m b^n$ ou $a^p b^q$
par induction sur ~~l'ordre~~
le nombre d'étape
de $S \rightarrow W$

Montrons qu'en ~~N~~ étapes S donne $a^m b^n$
en supposant que pour ~~P~~ N S ne donne
que $a^p b^q$ où des $a^r b^s$

Si j'ai une dérivation de W en N
 $N \rightarrow$ étapes étapes




par hypothèse de récurrence

W' est de la forme $a^p S b^p$
ou $a^k b^k$

Le 2^e cas est exclu

Car W' est $a^p S b^p$ et W est $a^{p+1} S b^{p+1}$
et tout a et b

$S \rightarrow GN \quad GV$



AdW parlent sur toute la
phrase et non juste sur le FV
sont les adverbes exprimant
le sentiment du locuteur.

Malheureusement,
l'aspirateur est jaune.

$S \rightarrow GN \quad GV$

$GN \rightarrow NP \quad | \quad NP \quad \underline{\text{qui}} \quad \cancel{GV}$

$GV \rightarrow VT \quad NP$

$NP \rightarrow \text{anne, bernard}$

$VT \rightarrow \text{regarde}$

bernard qui regarde amie' regarde bernard

NP

GN

VT

GV

NP

regarde

NP

GN

VT

GV

GN

S

$NP(q \in VTNP)^*$

$VT (qui VTNP)^*$

→ regulier

Autour des analyse des mots


chanteurs → chantier
l p pl
lubier

ils chantent quelques scènes des
années 70

T
3^e pers
pl
T
chanter l p pl lntense
≠

Grammaire non contextuelle

algo de parsing



extension pour avoir
l'accord
* il dorment → pb

DCG

