Vision logique de RDFS

HAI824 – Traitement sémantique des données ML Mugnier

CONTENU

- Rappels de RDF(S)
 - Graphe RDF(S): comporte à la fois des triplets « factuels » et des triplets
 « ontologiques »
 - Règles d'inférence RDF (« RDF entailment rules »)
 - Saturation d'un graphe avec les règles d'inférence
 - Interrogation d'un graphe RDF saturé avec une requête SPARQL
 (la sous-classe des Basic Graph Pattern Queries correspond aux CQ)
- Deux traductions RDFS → logique

qui produisent toutes deux une base de connaissances composée d'une base de faits et d'une base de règles Datalog

RDF Graph

An RDF graph G is a set of triples (s, p, o) where

- ▶ s is the subject (IRI or Blank)
- ▶ p is the property (IRI)
- o is the object (IRI, Blank or Literal)

Example



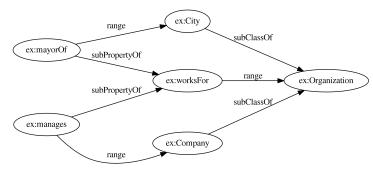


RDFS Ontology (RDF Schema)

An *RDFS ontology* declares semantic constraints between classes and properties using built-in properties:

- ▶ rdfs:subClassOf inclusion between classes
- ▶ rdfs:subPropertyOf inclusion between properties
- ▶ rdfs:domain class of the subject of a property
- rdfs:range class of the object of a property

Ontology Example



Main RDF Entailment Rules

In the rules below, a rule body defines a "pattern" that has to be found to apply the rule The letters p, o and s have to be replaced by values
The words subclass, subproperty, domain and range are prefixed by "rdfs:"

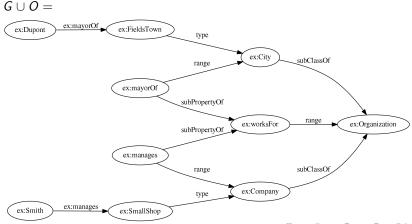
```
\begin{array}{l} (p, domain, o), (s_1, p, o_1) \rightarrow (s_1, type, o) \\ (p, range, o), (s_1, p, o_1) \rightarrow (o_1, type, o) \\ (p_1, subproperty, p_2), (p_2, subproperty, p_3) \rightarrow (p_1, subproperty, p_3) \\ (p_1, subproperty, p_2), (s, p_1, o) \rightarrow (s, p_2, o) \\ (s, subclass, o), (s_1, type, s) \rightarrow (s_1, type, o) \\ (s, subclass, o), (o, subclass, o_1) \rightarrow (s, subclass, o_1) \\ (p, domain, o), (o, subclass, o_1) \rightarrow (p, domain, o_1) \\ (p, range, o), (o, subclass, o_1) \rightarrow (p, range, o_1) \\ (p, subproperty, p_1), (p_1, domain, o) \rightarrow (p, domain, o) \\ (p, subproperty, p_1), (p_1, range, o) \rightarrow (p, range, o) \end{array}
```

These rules are not expressed in logic but a similar notion of homomorphism is defined to apply rules

RDF Entailment Rules (Sample)

Let $\mathcal R$ contain the following RDF entailment rules:

- 1. $(p_1, rdfs:subPropertyOf, p_2), (s, p_1, o) \rightarrow (s, p_2, o)$
- 2. $(p, rdfs:range, o), (s_1, p, o_1) \rightarrow (o_1, rdf:type, o)$
- 3. $(p, rdfs:range, o), (o, rdfs:subClassOf, o_1) \rightarrow (p, rdfs:range, o_1)$

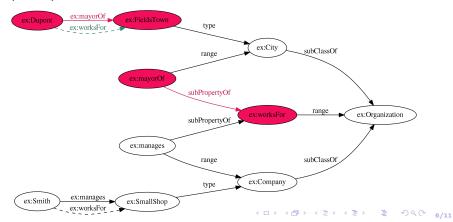


RDF Entailment Rules

 ${\cal R}$ contains the following RDF entailment rules:

- $1. \ (p_1, \operatorname{rdfs:subPropertyOf}, p_2), (s, p_1, o) \rightarrow (s, p_2, o)$
- 2. $(p, rdfs:range, o), (s_1, p, o_1) \rightarrow (o_1, rdf:type, o)$
- 3. $(p, rdfs:range, o), (o, rdfs:subClassOf, o_1) \rightarrow (p, rdfs:range, o_1)$

$$(G \cup O)^{\mathcal{R}} =$$

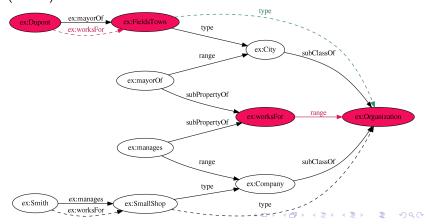


RDF Entailment Rules

 ${\cal R}$ contains the following RDF entailment rules:

- 1. $(p_1, rdfs:subPropertyOf, p_2), (s, p_1, o) \rightarrow (s, p_2, o)$
- 2. $(p, rdfs:range, o), (s_1, p, o_1) \rightarrow (o_1, rdf:type, o)$
- 3. $(p, rdfs:range, o), (o, rdfs:subClassOf, o_1) \rightarrow (p, rdfs:range, o_1)$

$$(G \cup O)^{\mathcal{R}} =$$

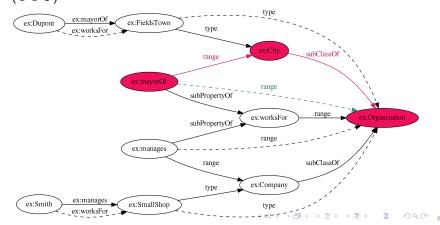


RDF Entailment Rules (we may also have non-standard RDF entailment rules)

 ${\cal R}$ contains the following RDF entailment rules:

- 1. $(p_1, rdfs:subPropertyOf, p_2), (s, p_1, o) \rightarrow (s, p_2, o)$
- 2. $(p, rdfs:range, o), (s_1, p, o_1) \rightarrow (o_1, rdf:type, o)$
- 3. $(p, rdfs:range, o), (o, rdfs:subClassOf, o_1) \rightarrow (p, rdfs:range, o_1)$

$$(G \cup O)^{\mathcal{R}} =$$



Basic Graph Pattern Query

A Basic Graph Pattern query is a conjunctive query on RDF triples.

Example

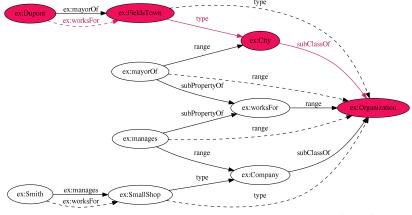
```
 \begin{aligned} \textit{q(pers, orgClass)} &\leftarrow & (\textit{pers}, \textit{ex:} worksFor, \textit{org}), \\ & & (\textit{org}, rdf:type, \textit{orgClass}), \\ & & (\textit{orgClass}, rdfs:subClassOf, \textit{ex:}Organization) \end{aligned}
```

SPARQL Syntax

```
SELECT ?pers ?orgClass
WHERE {
    ?pers ex:worksFor ?org.
    ?org rdf:type ?orgClass.
    ?orgClass rdfs:subClassOf ex:Organization.
}
```

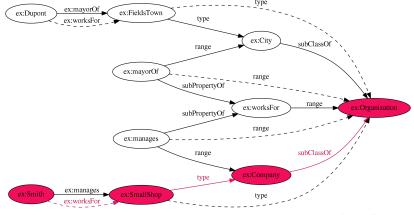
Query Answering Example

```
 \begin{aligned} \textit{q(pers, orgClass)} &\leftarrow & \textit{(pers, ex:worksFor, org)}, \\ & \textit{(org, rdf:type, orgClass)}, \\ & \textit{(orgClass, rdfs:subClassOf, ex:Organization)} \end{aligned}
```



Query Answering Example

```
 \begin{aligned} \textit{q(pers, orgClass)} &\leftarrow & \textit{(pers, ex:worksFor, org)}, \\ & \textit{(org, rdf:type, orgClass)}, \\ & \textit{(orgClass, rdfs:subClassOf, ex:Organization)} \end{aligned}
```



EN RDFS TOUT EST « TRIPLET »

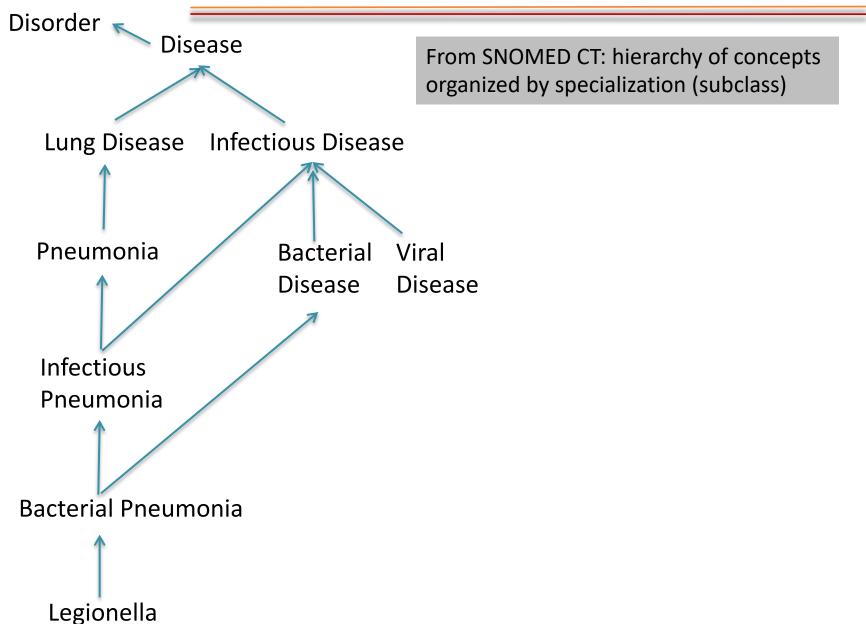
Triplets factuels (data)
 (s rdf:type o) // s instance, o classe
 (s p o) où p est une propriété « utilisateur » // s et o instances

- Triplets ontologiques
 - (s p o) où p ∈ { rdfs:subClassOf, rdfs:subPropertyOf,
 rdfs:domain, rdfs:range }
 // s et o sont des classes ou des propriétés selon le cas

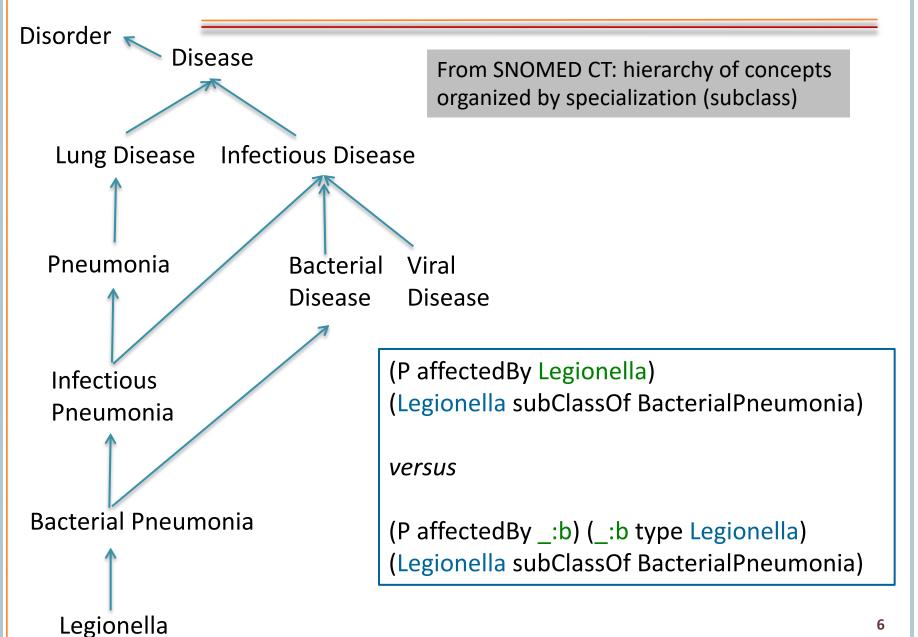
EN RDFS TOUT EST « TRIPLET »

Une entité peut être à la fois une instance, une classe et une propriété
 (Dupont, mayorOf, FieldsTown), (FieldsTown, rdf:type, City)
 (City, rdf:type, TypeOfHabitation)
 (Dupont, mayorOf, FieldsTown), (Dupont, rdf:type, mayorOf)
 (rdf:type rdf:type rdf:type) // triplet légal!

EXEMPLE : CLASSE UTILISÉE COMME L'UNE DE SES INSTANCES



EXEMPLE: CLASSE UTILISÉE COMME L'UNE DE SES INSTANCES



Première traduction logique de RDFS

On suit une approche classique de représentation des connaissances : séparation stricte entre classes / propriétés / instances de concept

classe → prédicat unaire (concept) propriété utilisateur → prédicat binaire (relation) instance (IRI, blank, littéral) → constante (instance)

On pourrait traduire les blanks par des variables existentielles mais on a supposé qu'on n'en avait pas dans nos bases de faits

(Dupont, mayorOf, FieldsTown)
(FieldsTown, type, City)
(City subClassOf Organization)
(mayorOf, subPropertyOf, worksFor)
(mayorOf, range, City)
(worksFor, range, Organization)

Prédicats:

City/1

Organization/1

mayorOf/2

worksFor/2

Constantes: Dupont, FieldsTown

Première traduction logique de RDFS

On suit une approche classique de représentation des connaissances : séparation stricte entre classes / propriétés / instances de concept

classe → prédicat unaire (concept) propriété utilisateur → prédicat binaire (relation) instance (IRI, blank, littéral) → constante (instance)

On pourrait traduire les blanks par des variables existentielles mais on a supposé qu'on n'en avait pas dans nos bases de faits

(Dupont, mayorOf, FieldsTown)
(FieldsTown, type, City)
(City subClassOf Organization)
(mayorOf, subPropertyOf, worksFor)
(mayorOf, range, City)
(worksFor, range, Organization)

Prédicats:

City/1

Organization/1

mayorOf/2

worksFor/2

Constantes: Dupont, FieldsTown

Remarque : on ne peut pas traduire le fait qu'une même appellation apparaisse à la fois comme classe/propriété/instance.

ex: (Dupont, mayorOf, City), (Dupont, type, mayorOf)

Première traduction logique de RDFS

```
Triplet factuel
                                                               fait
                                                               C(s)
            (s type C)
            (s p o) p utilisateur
                                                               p(s,o)
Triplet ontologique
                                                               règle Datalog
                                                               \forall x (A(x) \rightarrow B(x))
            (A subClassOf B)
             (r subPropertyOf s)
                                                               \forall x \forall y (r(x,y) \rightarrow s(x,y))
             (r domain A)
                                                                \forall x \forall y (r(x,y) \rightarrow A(x))
                                                               \forall x \forall y (r(x,y) \rightarrow B(y))
            (r range B)
```

Les triplets factuels fournissent une base de faits que l'on sature avec la base de règles provenant des triplets ontologiques => on ne peut donc pas requêter « l'ontologie »

EXEMPLE

```
(Dupont, mayorOf, FieldsTown)
(FieldsTown, type, City)
(City subClassOf Organization)
(mayorOf, subPropertyOf, worksFor)
(mayorOf, range, City)
(worksFor, range, Organization)
```

```
Prédicats :
City/1 concept
Organization/1 concept
mayorOf/2 propriété
worksFor/2 propriété
```

```
F = \{ \text{ mayorOf(Dupont, Fieldstown), City(FieldsTown)} \}
\mathcal{R} = \{ \\ \text{ City(x)} \rightarrow \text{ Organization(x)} \\ \text{ mayorOf(x,y)} \rightarrow \text{ worksFor(x,y)} \\ \text{ mayorOf(x,y)} \rightarrow \text{ City(y)} \\ \text{ worksFor(x,y)} \rightarrow \text{ Organization(y)} \\ \}
```

Deuxième traduction logique de RDFS

On suit l'approche RDF : on n'a que des triplets, la sémantique des triplets avec une propriété rdfs est donnée par les règles d'inférence RDFS

IRI, literal, blank → constante 1 seul prédicat (ternaire) : triple

(là aussi, on pourrait vouloir traduire un blank par une variable)

Traduction des triplets : $(s, p, o) \rightarrow triple(s, p, o)$

Le raisonnement est basé sur les règles d'inférence RDF(S)

Ex: (s, type, C1), (C1, subClassOf, C2) \rightarrow (s, type, C2)

 \forall s \forall C1 \forall C2 (triple(s,type,C1) \land triple(C1,subclass,C2) \rightarrow triple(s,type,C2))

Là aussi, on obtient une base de faits et un ensemble de règles Datalog

EXEMPLE

```
(Dupont, mayorOf, FieldsTown)
                                                           Prédicats : {triple/3}
(FieldsTown, type, City)
(City subClassOf Organization)
(mayorOf, subPropertyOf, worksFor)
(mayorOf, range, City)
(worksFor, range, Organization)
 F = { triple (Dupont, mayorOf, FieldsTown), ..., triple(worksFor, range, Organization) }
 \mathcal{R} = ensemble des règles d'inférence RDFS
F* = F U { triple(Dupont, worksFor, FieldsTown), triple(FieldsTown,type,Organization)
          triple(mayorOf,range,Organization) }
```

Le dernier triplet est obtenu en appliquant la règle RDFS

 $(p, range, o), (o, subclass, o_1) \rightarrow (p, range, o_1)$

C1 sous-classe de C2 ... sous-classe de Cn A a pour type C1

C1 sous-classe de C2 ... sous-classe de Cn A a pour type C1

```
Traduction 1

F = \{ C1(A) \}
R = \{ C1(x) \rightarrow C2(x),
...
Cn-1(x) \rightarrow Cn(x)
```

C1 sous-classe de C2 ... sous-classe de Cn A a pour type C1

Traduction 1

F = { C1(A) }

$$\mathcal{R}$$
 = { C1(x) \rightarrow C2(x),
...
Cn-1(x) \rightarrow Cn(x)

$$|F] = 1$$

 $|R| = n-1$
 $|F^*| = n$

C1 sous-classe de C2 ... sous-classe de Cn A a pour type C1

Traduction 1

```
F = \{ C1(A) \}
R = \{ C1(x) \rightarrow C2(x),
...
Cn-1(x) \rightarrow Cn(x)
```

$$|F] = 1$$

 $|R| = n-1$
 $|F^*| = n$

Traduction 2

en ne prenant que les 2 règles RDFS utiles

C1 sous-classe de C2 ... sous-classe de Cn A a pour type C1

Traduction 1

```
F = \{ C1(A) \}
R = \{ C1(x) \rightarrow C2(x),
...
Cn-1(x) \rightarrow Cn(x)
```

$$|F] = 1$$

 $|R| = n-1$
 $|F^*| = n$

Traduction 2

|F| = n les 2 règles RDFS utiles $|\mathcal{R}| = 2$

|F*| = n + n x (n-1)/2 même nombre d'atomes « factuels »
explosion (qui reste polynomiale) des atomes « ontologiques »

en ne prenant que

Intérêt de la traduction 2 pour le requêtage

Intérêt de la traduction 2 pour le requêtage

Intérêt de la traduction 2 pour le requêtage

```
q1(rel) \leftarrow (Dupont, rel, FieldsTown)
q2(pers, orgClass) \leftarrow (pers, worksFor, org), (org, type, orgClass),
                       (orgClass, subClassOf, Organization)
Traduction 1: on ne peut pas traduire vraiment ces requêtes
q11() ← mayorOf(Dupont,FieldsTown) // on peut juste demander si Dupont a
                                        // une certaine relation avec FiedsTown
q12() ← worksFor(Dupont,FieldsTown)
q2(pers) ← worksFor(pers,org)
                                        // Organization(org) sera inféré par une règle
Traduction 2:
q2(rel) \leftarrow triple(Dupont,rel,FieldsTown)
q2(pers, orgClass) ← triple(pers, worksFor, org),
                    triple(org, type, orgClass),
                     triple(orgClass, subClassOf, ex:Organization)
```

CONCLUSION

Les deux traductions produisent une base de faits et une base de règles Datalog

Traduction 1:

- (+) On suit une approche « représentation de connaissances » qui distingue clairement la partie ontologique de la partie factuelle
- (-) On ne peut donc pas traduire n'importe quel ensemble de triplets en gardant sa sémantique
- (-) On ne peut interroger que les faits provenant des triplets factuels et de leur saturation

Traduction 2:

- Tous les triplets deviennent des faits
- La base de règles est indépendante d'une base RDFS particulière
- (-) Il y a un grand nombre de triplets ontologiques inférés
- (+) On peut faire du « méta-raisonnement » : raisonner sur les classes et les propriétés
- (+) On peut « tout » interroger, y compris avec des requêtes portant à la fois sur les « vrais » faits et sur l'ontologie